Développez une preuve de concept

Never Give Up

Alan Blanchet

6 février 2024

Tuteur Neovision : Arthur DERATHE
Mentor OpenClassrooms : Chemsse EDDINE NABTI

Table des matières

1 Introduction

Le monde du Reinforcement Learning (RL) se rapproche de plus en plus de celui du Machine Learning (ML). De plus en plus d'approches utilisent des réseaux classiques tels que le ResNet[1] dans des algorithmes d'état de l'art comme IMPALA[2]. Réseaux de RL qui malgré son âge a pourtant toujours autant d'importance dans le domaine.

En RL, des recherches sont faites pour trouver des algorithmes qui permettent d'atteindre des objectifs de plus en plus complexes. Ces algorithmes se retrouvent toujours face à une problématique cruciale : 'Exploration vs Exploitation'.

Ce rapport a pour but de présenter l'algorithme 'Never Give Up' NGU[3] qui possède également des similarités avec le domain du ML. Il s'appuie sur une technique de récompense extrinsèque et intrinsèque pour maximiser l'exploration dans certains cas et la minimiser dans d'autres comme par exemple pour des observations redondantes ou des observations inutiles.

2 Contexte

Afin de comparer les résultats obtenus par NGU, des environnements standards sont utilisés comme ceux d'OpenAI Gym [4]. Ces environnements sont des jeux vidéo utilisés pour tester les performances des algorithmes de RL. Ils sont simples à utiliser mais cependant, ces environnements ne sont pas adaptés à des problèmes réels.

NGU essaye de résoudre les problèmes d'exploration lié à une policy (politique en français) π. La policy est une fonction qui prend en entrer une observation de l'environnement s et retourne une action a à effectuer. L'objectif de NGU est de trouver cette policy π qui maximise la somme des récompenses futures tout en explorant un maximum son environnement. La récompense future est définie comme la somme des récompenses à partir de l'état s jusqu'à la fin de l'épisode. C'est la fonction dont l'intérêt est d'être optimisée.

Pour y parvenir, il existe plusieurs familles d'algorithmes qui utilisent des approches différentes.

2.1 Model-based

Les algorithmes de type *model-based* utilisent un modèle de l'environnement pour effectuer des *simulations*. Ceux-ci incluent des algorithmes puissants comme AlphaZero[5]. AlphaGo qui a réussi à battre un champion du monde de Go en 2016 est un exemple d'algorithmes de type *model-based*. Cependant, ces algorithmes sont très gourmands en ressources et ne sont pas adaptés à des environnements complexes comme les jeux vidéo.

2.2 Model-free

Les algorithmes de type *model-free* n'utilisent pas de modèle de l'environnement. Dans ce type de configuration, l'agent apprend avec une méthode de *trial and error*. L'agent n'est pas capable d'auto-apprendre sur ses propres *simulations* et doit donc apprendre

directement sur l'environnement. Plusieurs algorithmes populaires sont issus de ce groupe d'algorithmes tel que PPO[6] ou TD3[7] C'est le cas de NGU.

2.3 On-policy

Les algorithmes de type *on-policy* peuvent être *model-free* ou *model-based*. Ceux-ci utilisent une seule policy π pour explorer l'environnement et y effectuer des actions. Les actions que l'agent réalise dans l'environnement sont basées sur la policy π_t qui est une fonction qui possède des poids définis par θ_t. La policy π_t est donc définie par $\pi_t(s, \theta_t)$. L'agent va donc apprendre à optimiser les poids θ_t de la policy π_t en fonction des récompenses qu'il reçoit. La différence primordiale avec une méthode *off-policy* est que l'agent est limité à un apprentissage sur une *transition* qui est issue de $\pi_t(s, \theta_t)$ uniquement. Ainsi, en effectuant une mise à jour de notre policy, on ne peut plus utiliser la *transition* car nous sommes à l'état s_{t+1} et non plus à l'état s_t. Cette méthode est généralement plus simple à implémenter car elle ne nécessite pas de stocker les *transitions* dans une mémoire tampon. Cependant, elle est moins efficace car l'agent ne peut pas apprendre sur des *transitions* passées.

2.4 Off-policy

Les algorithmes de type *off-policy* peuvent être *model-free* ou *model-based* tout comme le type *on-policy*. La différence fondamentale est qu'on peut tout à fait réutiliser des expériences passées pour entrainer notre agent. Cela permet d'augmenter la vitesse d'apprentissage de l'agent car il peut apprendre sur des *transitions* qu'il a déjà effectuées. Ainsi, on dit qu'on gagne en *sample efficiency*. Cependant, cette méthode est plus complexe à implémenter car il faut stocker les *transitions* dans une mémoire tampon. De plus, il faut faire attention à ne pas utiliser des *transitions* trop anciennes car l'agent pourrait apprendre sur des *transitions* qui ne sont plus représentatives de l'environnement actuel. Egalement, il faut faire attention à ne pas utiliser des *transitions* qui se chevauchent entre épisodes car cela pourrait biaiser l'apprentissage de l'agent. Ainsi, plein de concepts intéressants découlent de cette méthode comme les *replay buffer*s ou du *importance sampling*.

3 Algorithme

L'algorithme NGU[3] est une combinaison et amélioration de plusieurs algorithmes existants. Tout d'abord, un algorithme *Q-learning* est utilisé pour choisir une action en fonction d'un état donné. Plusieurs améliorations sont apportées à cet algorithme comme l'utilisation d'un deuxième réseau appelé *target network* qui possède exactement la même structure que notre policy. Le but de cette séparation est de stabiliser l'entrainement et de faire converger notre policy plus rapidement. Ainsi, on modifiera les poids de notre réseau *target* moins fréquemment que notre réseau utilisé pour récupérer une action à un instant t. En effet, si nous utilisions le même réseau pour choisir l'action et pour calculer la valeur de cette action, nous aurions un problème de *moving target* où on chercherait à effectuer une approximation d'un réseau qui est en constante évolution. Combiné avec des changements d'état parfois très fort, cela rendrait l'entrainement très instable. On obtient donc un autre algorithme, le DQN[8].

Le réseau DQN[8] possède une architecture assez traditionnelle en et utilise un module linéaire en dernière couche afin de proposer des actions en fonction d'une observation. Mais ce modèle ne permet pas de prendre en compte les actions passées. Par exemple dans le jeu de pong, le DQN ne peut pas connaitre la direction de la balle. Pour cela il y a plusieurs solutions. Le DQN propose une stratégie dite de *stacking* qui consiste à passer aux premières layers des séquences d'observations. Une autre pratique est d'utiliser un réseau récurrent RNN[9] qui permet de prendre en compte les actions passées. On utilise plus courrement un LSTM[10]. Avec cette combinaison de réseaux ML classiques et LSTM on obtient réseau DRQN[11].

L'algorithme DRQN[11] permet donc de prêter attention à différentes séquences passées. Les auteurs du DRQN[11] précisent que leur algorithme n'améliore pas les performances du DQN[8]. Cependant, il est plus stable et permet de réduire le temps d'entrainement. C'est donc un bon compromis entre performance et temps d'entrainement. Cependant, il est possible d'aller plus loin en utilisant un réseau récurrent plus complexe. C'est ce que propose l'algorithme R2D2[12] en incluent plusieurs améliorations.

R2D2[12] ajoute la fonctionnalité de lancer plusieurs algorithmes DRQN[11] en parralèle dans des environnements qui leur est propre. Ainsi R2D2[12] possède son propre réseau central DRQN[11] sur lequel l'entrainement sera effectué. Les réseaux à l'intérieur des processus en parallèle ont pour unique but de récupérer des données avec une policy fixe. Cette policy sera mise à jour selon une fréquence que l'on peut définir de l'agent central vers l'agent dans le processus.

R2D2[12] ajoute également une amélioration sur le sampling des données. Il propose d'utiliser une liste de priorités pour pondérer les différentes trajectoires de notre buffer. Ainsi, les trajectoires les plus intéressantes seront plus souvent utilisées pour l'entrainement. Cela permet de réduire le temps d'entrainement et d'augmenter la convergence.

Finalement, le réseau NGU[3] vient également se greffer à tous ces travaux.

NGU[3] cherche à guider l'agent vers des états qui pourraient l'intéresser en maximisant l'exploration et en attribuant un bonus d'exploration au calcul final de la récompense (intrinsic reward). Plus le réseau explore l'environnement, moins ce bonus est attribué à l'agent. Cette méthode s'appelle *curiosity-driven exploration*.

Le papier propose de séparer le reward en deux catégories. Le reward classique que l'agent obtient en effectuant des actions qui maximisent son reward de l'environnement et un reward d'exploration qui incite l'agent à effectuer des explorations.

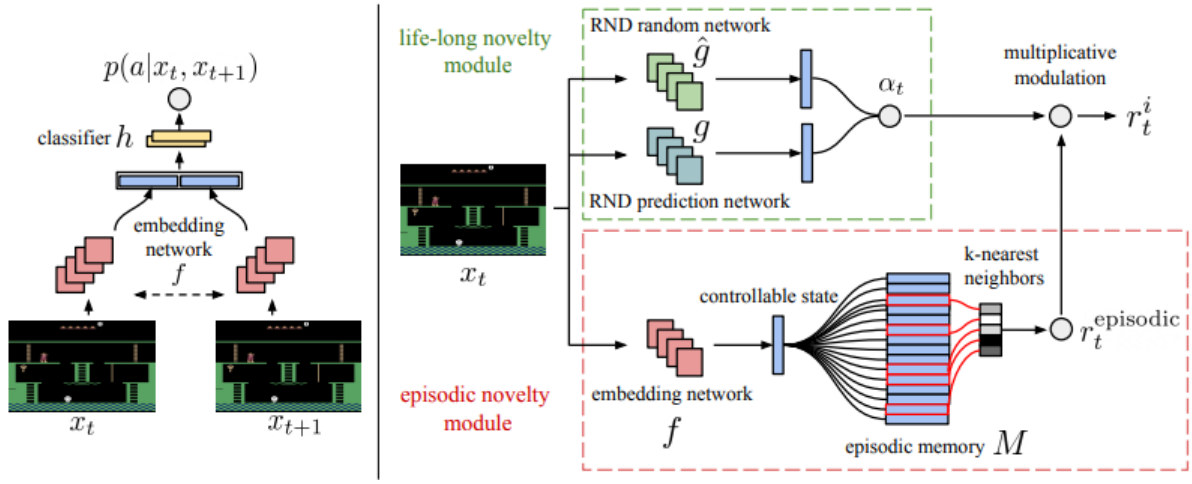

FIGURE 1 – Schéma de l'algorithme NGU[3]

3.1 Reward

Le papier utiliser une technique de *reward shaping* pour attribuer un reward d'exploration à l'agent. Ce reward s'appelle le *intrinsic reward* r^i et est calculé à partir de deux sous-rewards. Un dans leur *episodic novelty module* $r^{episodic}$ et un autre dans le *life-long novelty module* α. La formule est la suivante :

$$r_t^i = r_t^{episodic} \cdot min\{max\{\alpha_t, 1\}, L\}$$

Dans le papier, les auteurs ont choisit $L = 5$.

3.2 Episodic novelty module

L'*episodic novelty module* est un reward d'exploration qui est attribué à l'agent lorsqu'il visite un état qu'il n'a pas encore visité dans un épisode. Ce reward est calculé en fonction de la distance entre deux *controllable states* qui correspond à un embedding d'un état. Plus l'agent est loin d'un état qu'il a déjà visité dans un épisode, plus le reward d'exploration est élevé. C'est ce qui va permettre à l'agent de ne pas refaire les mêmes actions dans un épisode. L'embedding est ajouté au *replay buffer* pour ensuite plus facilement être comparé avec les embeddings des états futurs. Cette comparaison s'effectue en calculant la distance grâce à la fonction K qui représente un algorithme traditionnel de K-Nearest Neighbors. La formule est la suivante :

$$r_t^{episodic} = \frac{\beta}{\sqrt{\sum_{x_i \in N_k} K(f(x_t), f(x_i))} + c}$$

c est une constante permettant d'éviter une division par 0. K est la fonction de distance. x_i sont les embeddings observés dans un épisode.

Pour calculer ces embeddings, les auteurs utilisent un réseau de neuronnes f qui prend en entrer un état et qui renvoie un embedding. Pour ce faire, le réseau est entrainé sur un autre réseau d'*inverse dynamics* qui prend en entrée deux embeddings des états s_t et s_{t+1}, puis les concatène pour prédire l'action qui a été effectuée pour passer de s_t à s_{t+1}. La formule est la suivante :

$$p(a|x_t, x_{t+1}) = h(f(x_t), f(x_{t+1}))$$

h étant un réseau qui concatène ses deux entrées et qui renvoie une action. En entrainant ce réseau, on entraine également le réseau f à trouver des embeddings qui permettent de prédire des actions.

Cette technique permet également de résoudre le problème du *noisy TV* où l'agent maximise son reward d'exploration en n'effectuant aucune action. L'agent obtient son reward uniquement un observant l'environnement changer. Ainsi avec cette méthode, si l'erreur de prédiction de l'action avec deux états est élevée, l'agent sera encouragé à effectuer des actions pour réduire cette erreur.

3.3 Life-long novelty module

L'algorithme dispose également d'un *life-long novelty module* qui permet de calculer un reward d'exploration sur le long terme. Ce module permet de décourager l'agent à visiter des états qu'il a déjà visités dans d'autres épisodes. Ainsi, si dans un épisode on a un bonus $r_t^{episodic}$ élevé et identique pour des états identiques entre épisodes, le *life-long* reward quant à lui sera plus faible pour le deuxième épisode. C'est ce mécanisme qui guide l'agent vers des états qu'il n'a pas encore visité inter-épisodes.

Le life-long novelty module α est calculé de la manière suivante :

$$\alpha_t = 1 + \frac{err(x_t) - \mu_e}{\sigma_e}$$

μ_e et σ_e sont respectivement la moyenne mobile et l'écart-type mobile épisodiques.

$err(x)$ est calculé d'une façon spéciale. Les auteurs utilisent un réseau RND[13]. Ce réseau est composé de deux modules dont les poids sont initialisés aléatoirements. On va considérer un réseau comme état notre target et l'autre notre réseau de prédiction. Ainsi, lorsqu'un état un qui "sort du lot" sera découvert, on aura une erreur de prédiction élevée. C'est cette erreur qui sera utilisée pour calculer le reward d'exploration long-terme.

3.4 Augmented reward

La combinaison de ces rewards nous donne un *augmented reward*. Il se calcul de cette façon :

$$r_t = r_t^e + \beta r_t^i$$

On remarque que le reward d'exploration est multiplié par un facteur β qui permet de régler l'importance de l'exploration dans l'entrainement de l'agent. Plus β est élevé, plus l'agent sera encouragé à explorer son environnement. Les auteurs utilisent plusieurs valeurs de β avec l'algorithme R2D2[12]. Cela leur permet d'avoir plusieurs policies dont certaines qui cherchent à explorer un maximum l'environnement et d'autres qui cherchent à maximiser le reward de l'environnement. Pour leurs expériences avec plusieurs β, $\beta = 0$, ce qui fait qu'il y a toujours une policy qui n'utilise que le reward exploité de l'environnement. En tous, les auteurs utilisent 256 policies différentes.

Plus l'agent explore l'environnement et devient familier avec celui-ci, plus le bonus d'exploration disparait et l'apprentissage est uniquement guidé par les rewards extrinsèques.

4 Résultats

4.1 Environnements

Pour obtenir des résultats du réseau, les auteurs ont utilisé les jeux Atari grâce à la librairie OpenAI Gym [4]. Cette librairie expose des jeux vidéo classiques qui sont utilisés pour tester les performances des algorithmes de RL.

4.2 Papier

L'essence même du papier est de montrer qu'il peut mieux performer dans des environnements où l'exploration est primordiale. Ainsi, des tests ont été effectués sur des jeux où le score était auparavant très faible dû à un manque d'exploration de l'agent. Ces jeux comprennent *Montezuma's Revenge*, *Pitfall !*, *Private Eye*, *Solaris* et *Venture*. Ils ont également comparé les résultats avec des jeux où l'exploration est beaucoup moins pertinente. C'est-à-dire dans des jeux avec des rewards *dense* (qui sont donnés fréquemment) comme *Beam Rider*, *Breakout*, *Enduro*, *Pong* et *Q*bert*.

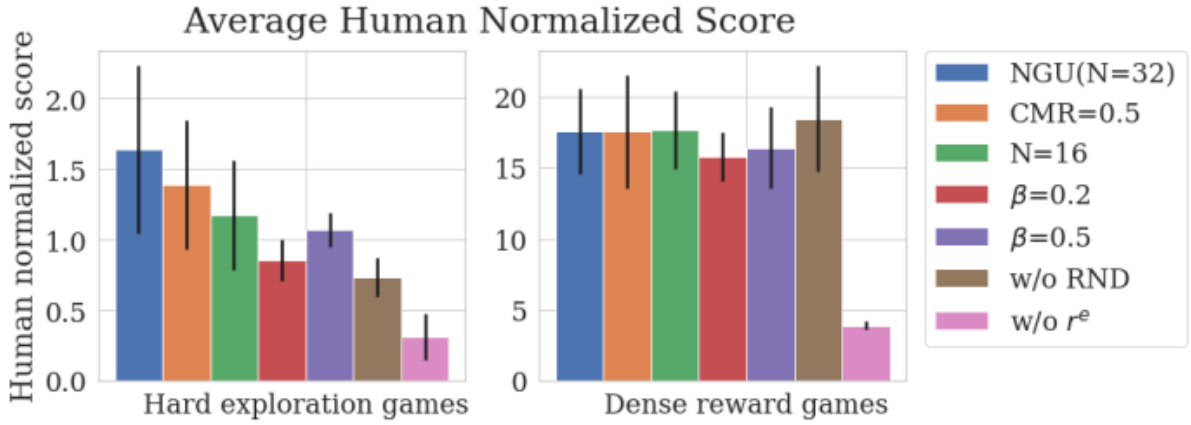

FIGURE 2 – Différentes configurations de NGU sur les jeux Atari avec un reward *dense* et *sparse*

Algorithm	Gravitar	MR	Pitfall!	PrivateEye	Solaris	Venture
Human	3.4k	4.8k	6.5k	69.6k	**12.3k**	1.2k
Best baseline	**15.7k**	**11.6k**	0.0	11k	5.5k	2.0k
RND	3.9k	10.1k	-3	8.7k	3.3k	1.9k
R2D2+RND	15.6k±0.6k	10.4k±1.2k	-0.5±0.3	19.5k±3.5k	4.3k±0.6k	**2.7k±0.0k**
R2D2(Retrace)	13.3k±0.6k	2.3k±0.4k	-3.5±1.2	32.5k±4.7k	6.0k±1.1k	2.0k±0.0k
NGU(N=1)-RND	12.4k±0.8k	3.0k±0.0k	**15.2k±9.4k**	40.6k±0.0k	5.7k±1.8k	46.4±37.9
NGU(N=1)	11.0k±0.7k	8.7k±1.2k	9.4k±2.2k	60.6k±16.3k	5.9k±1.6k	876.3±114.5
NGU(N=32)	14.1k±0.5k	10.4k±1.6k	8.4k±4.5k	**100.0k±0.4k**	4.9k±0.3k	1.7k±0.1k

FIGURE 3 – Résultats comparés aux algorithmes *baseline*, RND et R2D2. La baseline comprend les algorithmes DQN + PixelCNN [14], DQN + CTS et PPO + CoEx [15]

On remarque que NGU ne performe pas mieux partout. Il est plus performant sur Pitfall ! et Private Eye et ce avec des paramètres différents.

4.3 Mon implémentation

Mon implémentation est présente dans un répertoire github [1]. Elle comprend du code d'un autre répertoire github de 'Coac' [2] ainsi que mes modifications.

J'ai d'abord commencé par implémenter les versions DQN, DRQN puis R2D2. Mais mon code ne s'adaptait pas facilement à l'algorithme NGU car cela m'aurait fait casser toute ma structure du replay buffer. J'ai donc préféré récupérer l'implémentation de 'Coac' qui était déjà fonctionnelle mais ne possède quant à elle pas l'implémentation de R2D2.

J'ai apporté des modifications au code afin de pouvoir le tester sur le jeu choisi, *Montezuma's Revenge*. J'ai également ajouté des logs pour pouvoir suivre l'évolution de l'entrainement à travers Tensorboard. L'implémentation ne prennait pas en compte l'image de l'environnement. J'ai donc dû modifier le code pour intégrer les observations 2D, les encoder en 1D dans l'objectif d'ensuite pouvoir construire l'embedding de NGU.

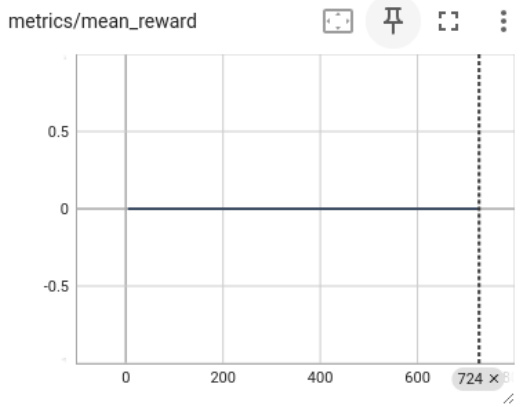

(a) Reward extrinsèque après 724 épisodes

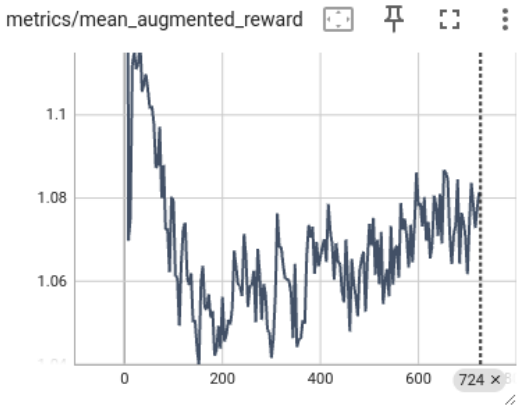

(b) Reward extrinsèque (0) + intrinsèque après 724 épisodes

1. https://github.com/AlanBlanchet/DeveloppezUnePreuveDeConcept
2. https://github.com/Coac/

Dans les résultats ci-dessus, on peut voir qu'il n'y a aucun reward extrinsèque *mean reward* tandis que le reward total (extrinsèque+intrinsèque) *mean augmented reward* est lui bien présent.

L'algorithme a été entrainé pendant 8h et a parcouru un total de 72 500 frames sur un GPU RTX4070 Ti de nvidia. Dans le papier, plus de 35 milliards de frames ont été parcourues. Soit une équivalence de 440 ans d'entrainement pour mon cas.

5 Conclusion

Pour ce projet de Preuve de Concept, j'ai appris énormement de choses sur les approches de Reinforcement Learning de manière générale. Je n'avais pas encore de notions dans le domaine et était uniquement familier avec les approches type ML. J'ai donc découvert des librairies, des sources d'informations, des papiers ou encore des articles de blog qui m'ont permis d'avancer fortement dans le domaine.

J'ai également pu m'améliorer en développement distribué sous Python, qui est moins simple que dans d'autres langages où le terme de *thread* y est plutôt standard.

Références

[1] Kaiming He et al. *Deep Residual Learning for Image Recognition*. https://arxiv.org/pdf/1512.03385.pdf. 2020.

[2] Lasse Espeholt et al. *IMPALA: Scalable Distributed Deep-RL with Importance Weighted Actor-Learner Architectures*. https://arxiv.org/pdf/1802.01561.pdf. 2018.

[3] Adrià Puigdomènech Badia et al. *NEVER GIVE UP: LEARNING DIRECTED EXPLORATION STRATEGIES*. https://openreview.net/pdf?id=Sye57xStvB. 2020.

[4] Greg Brockman et al. *OpenAI Gym*. https://arxiv.org/pdf/1606.01540.pdf. 2016.

[5] David Silver et al. *Mastering Chess and Shogi by Self-Play with a General Reinforcement Learning Algorithm*. https://openreview.net/pdf?id=Sye57xStvB. 2017.

[6] John Schulman et al. *Proximal Policy Optimization Algorithms*. https://arxiv.org/pdf/1707.06347.pdf. 2017.

[7] Scott Fujimoto, Herke van Hoof et David Meger. *Addressing Function Approximation Error in Actor-Critic Methods*. https://arxiv.org/pdf/1802.09477.pdf. 2018.

[8] Volodymyr Mnih et al. *Playing Atari with Deep Reinforcement Learning*. https://arxiv.org/pdf/1312.5602.pdf. 2013.

[9] David E. Rumelhart, Geoffrey E. Hinton et Ronald J. Williams. *Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) Network*. https://apps.dtic.mil/dtic/tr/fulltext/u2/a164453.pdf. 1985.

[10] Sepp Hochreiter et Jürgen Schmidhuber. *LONG SHORT-TERM MEMORY*. https://www.bioinf.jku.at/publications/older/2604.pdf. 1997.

[11] Matthew Hausknecht et Peter Stone. *Deep Recurrent Q-Learning for Partially Observable MDPs*. https://arxiv.org/pdf/1507.06527.pdf. 2017.

[12] Steven Kapturowski et al. *RECURRENT EXPERIENCE REPLAY IN DISTRIBUTED REINFORCEMENT LEARNING*. https://openreview.net/pdf?id=r1lyTjAqYX. 2019.

[13] Yuri Burda et al. *EXPLORATION BY RANDOM NETWORK DISTILLATION*. https://arxiv.org/pdf/1810.12894.pdf. 2018.

[14] Georg Ostrovski et al. *Count-Based Exploration with Neural Density Models*. https://arxiv.org/pdf/1703.01310.pdf. 2017.

[15] Jongwook Choi et al. *CONTINGENCY-AWARE EXPLORATION IN REINFORCEMENT LEARNING*. https://arxiv.org/pdf/1811.01483.pdf. 2019.